

Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης  
Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών



Υπολογιστική Νοημοσύνη

Αναφορά Εργασίας 3. Regression

Τίτλος:

Επίλυση προβλήματος παλινδρόμησης με χρήση μοντέλων TSK

Φοιτήτρια: Ζαχαριουδάκη Δανάη

A.M.: 9418

Ημερομηνία: Οκτώβριος 2025

## Περιεχόμενα

|          |                                                                    |           |
|----------|--------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Εφαρμογή 1: Απλό Dataset</b>                                    | <b>2</b>  |
| 1.1      | Εκπαίδευση . . . . .                                               | 2         |
| 1.2      | TSK Model 1 . . . . .                                              | 3         |
| 1.3      | TSK Model 2 . . . . .                                              | 5         |
| 1.4      | TSK Model 3 . . . . .                                              | 7         |
| 1.5      | TSK Model 4 . . . . .                                              | 9         |
| 1.6      | Μετρικές απόδοσης . . . . .                                        | 11        |
| 1.7      | Αποτελέσματα . . . . .                                             | 12        |
| <b>2</b> | <b>Εφαρμογή 2: Dataset με Υψηλή Διαστασιμότητα</b>                 | <b>13</b> |
| 2.1      | Διαχωρισμός σε σύνολα εκπαίδευσης - επικύρωσης - ελέγχου . . . . . | 14        |
| 2.2      | Επιλογή των βέλτιστων παραμέτρων . . . . .                         | 14        |
| 2.3      | Εκπαίδευση ενός TSK μοντέλου . . . . .                             | 17        |
| 2.4      | Σχολιασμός . . . . .                                               | 20        |

# 1 Εφαρμογή 1: Απλό Dataset

Για το πρώτο μέρος της εργασίας, ο κώδικας που υπολοιεί την εκπαίδευση και αξιολόγηση των μοντέλων βρίσκεται στο αρχείο TSK\_Regression.m. Κάνουμε χρήση του Airfoil Self-Noise dataset από το UCI repository. Περιλαμβάνονται 1503 δείγματα (*instances*) με 6 χαρακτηριστικά (*features*), από τα οποία τα 5 είναι δεδομένα εκμάθησης και το 6ο η τιμή εξόδου. Στόχος μας είναι η διερεύνηση της διαδικασίας εκπαίδευσης και αξιολόγησης ασαφών νερωνικών μοντέλων.

## 1.1 Εκπαίδευση

Αρχικά ζητείται να γίνει διαχωρισμός του συνόλου δεδομένων σε τρία μη-επικαλυπτόμενα υποσύνολα:

1. Υποσύνολο εκπαίδευσης (Training set)
2. Υποσύνολο επικύρωσης (Validation set)
3. Υποσύνολο ελέγχου (Test set)

Αυτά αντιστοιχίζονται στις μεταβλητές του κώδικα *'Dtrn'*, *Dval*, και *Dtst* αντίστοιχα. Ο διαχωρισμός του *dataset* έγινε με χρήση της συνάρτησης *'split\_scale'*, η οποία χωρίζει το σύνολο των δεδομένων ως εξής:

- 60% στο σύνολο εκπαίδευσης
- 20% στο σύνολο επικύρωσης
- 20% στο σύνολο ελέγχου

αλλά πραγματοποιεί και προεπεξεργασία (*scaling*), δηλαδή κανονικοποίηση ανάλογα με την τιμή της μεταβλητής *preproc*, η οποία στον κώδικά μας παίρνει την τιμή 1 (unit hypercube), για να έχουμε κανονικοποίηση στο  $[0,1]$ .

Στα πλαίσια της μελέτης εκπαιδεύτηκαν 4 *TSK* μοντέλα, στα οποία μεταβάλλονται η μορφή της εξόδου αλλά και το πλήθος των συναρτήσεων συμμετοχής για κάθε μεταβλητή εισόδου όπως φαίνεται στο Σχ. 1.

| Πλήθος συναρτήσεων συμμετοχής |   | Μορφή εξόδου |
|-------------------------------|---|--------------|
| TSK_model_1                   | 2 | Singleton    |
| TSK_model_2                   | 3 | Singleton    |
| TSK_model_3                   | 2 | Polynomial   |
| TSK_model_4                   | 3 | Polynomial   |

Σχήμα 1: TSK models.

Για τη δημιουργία και εκπαίδευση κάθε μοντέλου χρησιμοποιήθηκαν οι συναρτήσεις *genfis* και *anfis*. Όλα τα μοντέλα εκπαιδεύτηκαν με την υβριδική μέθοδο, με τη βελτιστοποίηση των συναρτήσεων συμμετοχής να γίνεται μέσω της μεθόδου της οπισθοδιάσωσης (*backpropagation*), ενώ η βελτιστοποίηση των παραμέτρων της πολυωνυμικής συνάρτησης εξόδου γίνεται μέσω της μεθόδου των ελαχίστων τετραγώνων (Least Squares). Οι συναρτήσεις συμμετοχής είναι bell-shaped και τα ασαφή σύνολα παρουσιάζουν σε κάθε είσοδο βαθμό επικάλυψης περίπου 0.5. Για κάθε μοντέλο αρχικοποιήθηκε ο αριθμός συναρτήσεων συμμετοχής και η μορφή της εξόδου με βάση τα ζητούμενα του προβλήματος. Η εκπαίδευση έγινε για 100 *epochs* και για κάθε μοντέλο έγινε χρήση ενός χρονιστή για να καταγράφεται ο χρόνος ο οποίος απαιτήθηκε για την ολοκλήρωση της εκπαίδευσης (*training\_time*). Ο χρόνος εκπαίδευσης για κάθε μοντέλο παρουσιάζεται στον πίνακα 1.

Table 1: Training time for each TSK model

| Model       | Training Time (s) |
|-------------|-------------------|
| TSK Model 1 | 1.73              |
| TSK Model 2 | 20.96             |
| TSK Model 3 | 7.57              |
| TSK Model 4 | 1570.38           |


## 1.2 TSK Model 1

```
ANFIS info:
  Number of nodes: 92
  Number of linear parameters: 32
  Number of nonlinear parameters: 30
  Total number of parameters: 62
  Number of training data pairs: 902
  Number of checking data pairs: 300
  Number of fuzzy rules: 32
```


Σχήμα 2: TSK model 1.

Τα διαγράμματα συναρτήσεων συμμετοχής όπου απεικονίζονται οι τελικές μορφές των ασαφών συνόλων που προέκυψαν μέσω της διαδικασίας εκπαίδευσης φαίνονται στο Σχ. 3.


Το διάγραμμα μάθησης (*Learning curve*) όπου απεικονίζεται το σφάλμα εκπαίδευσης και το σφάλμα επικύρωσης του μοντέλου συναρτήσει του αριθμού των επαναλήψεων φαίνεται στο Σχ. 4, ενώ το διάγραμμα με το σφάλμα πρόβλεψης στο Σχ. 5.




( $\alpha'$ ) Input 1: Frequency




( $\beta'$ ) Input 2: Angle of attack



( $\gamma'$ ) Input 3: Chord length




( $\delta'$ ) Input 4: Free-stream velocity




( $\epsilon'$ ) Input 5: Suction-side displacement thickness

Σχῆμα 3: Membership functions.



Σχήμα 4: Learning Curve of TSK model 1.



Σχήμα 5: Prediction Error of TSK model 1.


### 1.3 TSK Model 2

Αντίστοιχα παρατίθενται για το δεύτερο μοντέλο τα διαγράμματα συναρτήσεων συμμετοχής στο Σχ. 7, το διάγραμμα μάθησης (*Learning curve*) στο Σχ. 8 και το διάγραμμα με το σφάλμα πρόβλεψης στο Σχ. 9.


# ANFIS info:

Number of nodes: 524  
 Number of linear parameters: 243  
 Number of nonlinear parameters: 45  
 Total number of parameters: 288  
 Number of training data pairs: 902  
 Number of checking data pairs: 300  
 Number of fuzzy rules: 243


Σχήμα 6: TSK model 2.




( $\alpha'$ ) Input 1: Frequency




( $\beta'$ ) Input 2: Angle of attack



( $\gamma'$ ) Input 3: Chord length




( $\delta'$ ) Input 4: Free-stream velocity




( $\epsilon'$ ) Input 5: Suction-side displacement thickness

Σχήμα 7: Membership functions.



Σχήμα 8: Learning Curve of TSK model 2.



Σχήμα 9: Prediction Error of TSK model 2.

#### 1.4 TSK Model 3


Αντίστοιχα για το τρίτο μοντέλο, τα διαγράμματα συναρτήσεων συμμετοχής στο Σχ. 11, το διάγραμμα μάθησης (*Learning curve*) στο Σχ. 12 και το διάγραμμα με το σφάλμα πρόβλεψης στο Σχ. 13.




### ANFIS info:

Number of nodes: 92  
 Number of linear parameters: 192  
 Number of nonlinear parameters: 30  
 Total number of parameters: 222  
 Number of training data pairs: 902  
 Number of checking data pairs: 300  
 Number of fuzzy rules: 32


Σχήμα 10: TSK model 3.




( $\alpha'$ ) Input 1: Frequency




( $\beta'$ ) Input 2: Angle of attack



( $\gamma'$ ) Input 3: Chord length




( $\delta'$ ) Input 4: Free-stream velocity




( $\epsilon'$ ) Input 5: Suction-side displacement thickness

Σχήμα 11: Membership functions.



Σχήμα 12: Learning Curve of TSK model 3.



Σχήμα 13: Prediction Error of TSK model 3.


### 1.5 TSK Model 4

Και τέλος για το τέταρτο και τελευταίο μοντέλο, τα διαγράμματα συναρτήσεων συμμετοχής στο Σχ. 15, το διάγραμμα μάθησης (*Learning curve*) στο Σχ. 16 και το διάγραμμα με το σφάλμα πρόβλεψης στο Σχ. 17.


# ANFIS info:

Number of nodes: 524  
 Number of linear parameters: 1458  
 Number of nonlinear parameters: 45  
 Total number of parameters: 1503  
 Number of training data pairs: 902  
 Number of checking data pairs: 300  
 Number of fuzzy rules: 243


Σχήμα 14: TSK model 4.




( $\alpha'$ ) Input 1: Frequency




( $\beta'$ ) Input 2: Angle of attack



( $\gamma'$ ) Input 3: Chord length




( $\delta'$ ) Input 4: Free-stream velocity




( $\epsilon'$ ) Input 5: Suction-side displacement thickness

Σχήμα 15: Membership functions.



Σχήμα 16: Learning Curve of TSK model 4.



Σχήμα 17: Prediction Error of TSK model 4.

## 1.6 Μετρικές απόδοσης

Ο υπολογισμός της πρόβλεψης του μοντέλου έγινε με χρήση της συνάρτησης *evalfis*, η οποία έπειτα χρησιμοποιήθηκε για τον υπολογισμό των δεικτών απόδοσης, που παρουσιάζονται για κάθε μοντέλο στον πίνακα 2.

Table 2: Performance metrics for the TSK models

| Metric | TSK Model 1 | TSK Model 2 | TSK Model 3 | TSK Model 4 |
|--------|-------------|-------------|-------------|-------------|
| MSE    | 14.320      | 18.239      | 8.8675      | 6.4304      |
| RMSE   | 3.7842      | 4.2707      | 2.9778      | 2.5358      |
| $R^2$  | 0.7203      | 0.6438      | 0.8268      | 0.8744      |
| NMSE   | 0.2797      | 0.3562      | 0.1732      | 0.1256      |
| NDEI   | 0.5288      | 0.5968      | 0.4162      | 0.3544      |

### 1.7 Αποτελέσματα

Καταρχήν, η πρώτη παρατήρηση που έγινε κατά την επανάληψη της διαδικασίας της εκπαίδευσης είναι ότι εξαιτίας της τυχαιότητας που εισάγεται από την συνάρτηση `split_scale` κατά το διαχωρισμό του *dataset* σε κάθε νέα εκτέλεση, παίρνουμε κάθε φορά διαφορετικές μορφές για τα ασαφή σύνολα και κατά συνέπεια διαφορετικά αποτελέσματα για κάθε μοντέλο.

Όσον αφορά στην απόδοση, συγκρίνοντας τα 2 πρώτα μοντέλα μεταξύ τους, τα οποία έχουν κοινή μορφή εξόδου *Singleton* και διαφέρουν ως προς τον αριθμό των συναρτήσεων συμμετοχής, παρατηρούμε πως το μοντέλο 1, με 2 συναρτήσεις συμμετοχής, έχει χαμηλότερες τιμές για όλες τις μετρικές απόδοσης, εκτός από τον συντελεστή προσδιορισμού  $R^2$  ο οποίος είναι μια έκφραση του πόσο καλά εξηγεί το μοντέλο μας τη διακύμανση των πραγματικών δεδομένων. Παρατηρώντας την καμπύλη μάθησης του μοντέλου 2, γίνεται σαφές πως έχουμε υπερεπροσαρμογή (*overfitting*), αφού ενώ το *training error* μειώνεται σταθερά, το *validation error* αρχίζει να αυξάνεται μετά τις 20 επαναλήψεις παρουσιάζοντας μεγάλες ταλαντώσεις. Αυτό σημαίνει πως το μοντέλο προσαρμόζεται υπερβολικά στα δεδομένα εκπαίδευσης, χάνοντας την ικανότητά του για γενίκευση, πράγμα το οποίο δεν συμβαίνει στην περίπτωση του μοντέλου 1. Συμπεραίνουμε πως η αύξηση των συναρτήσεων συμμετοχής στην περίπτωση αυτή δημιουργήσε υπερβολική πολυπλοκότητα για την συγκεκριμένη μορφή εξόδου οδηγώντας σε υπερεπροσαρμογή. Αντίστοιχα για το μοντέλο 1 μπορούμε να πούμε πως γενικεύει σωστά αλλά έχει περιορισμένη ικανότητα έκφρασης. Είναι δηλαδή χαμηλής πολυπλοκότητας αλλά δεν μπορεί να αποδώσει λεπτές διαφοροποιήσεις στα δεδομένα.

Επαναλαμβάνοντας την ίδια διαδικασία για τα μοντέλα 3 και 4 με έξοδο *Polynomial*, βλέπουμε πως οι μετρικές και των 2 είναι πολύ καλύτερες συγκριτικά με τα μοντέλα 1 και 2. Τα μοντέλα 3 και 4 δηλαδή αποδίδουν καλύτερα, με χαμηλότερο MSE, RMSE, NMSE, NDEI και υψηλότερο  $R^2$ . Μεταξύ των 2, το μοντέλο 4 υπερτερεί επίσης του μοντέλου 3, με *RMSE* 2.5358 έναντι 2.9778, *NMSE* 0.12558 έναντι 0.17318 και  $R^2$  0.87442 έναντι 0.82682. Από την καμπύλη εκμάθησης του μοντέλου 4, παρόμοια με αυτή του μοντέλου 3 παρατηρούμε ότι τόσο το σφάλμα εκπαίδευσης όσο και το σφάλμα επικύρωσης μειώνονται ομαλά και σταθεροποιούνται με παρόμοια πορεία, γεγονός που μαρτυρά την απουσία έντονης υπερεπροσαρμογής. Η υψηλότερη τιμή του σφάλματος επικύρωσης υποδηλώνει ένα σφάλμα

γενίκευσης, το οποίο οφείλεται στην αυξημένη πολυπλοκότητα του μοντέλου, ειδικά στην περίπτωση του μοντέλου 4. Επίσης, εδώ η αύξηση των συναρτήσεων συμμετοχής φαίνεται να βελτιώνει την απόδοση σε αντίθεση με την αντίστοιχη αύξηση σε έξοδο *Singleton*. Το μοντέλο 4 φαίνεται να παρουσιάζει την καλύτερη ισορροπία πολυπλοκότητας και ακρίβειας. Προκύπτει τελικώς, πως η πολυωνυμική μορφή εξόδου προσφέρει μεγαλύτερη εκφραστικότητα, μπορεί να προσεγγίσει πιο σύνθετες σχέσεις με την εισαγωγή πολυωνυμικών όρων, παρέχοντας καλύτερη απόδοση. Γενικά μπορούμε να συμπεράνουμε πως η μορφή εξόδου επηρεάζει σημαντικά την απόδοση, ενώ η αύξηση των συναρτήσεων συμμετοχής πρέπει να γίνεται προσεκτικά, γιατί η πολυπλοκότητα χωρίς ανάλογη εκφραστικότητα οδηγεί σε υπερπροσαρμογή.

## 2 Εφαρμογή 2: Dataset με Υψηλή Διαστασιμότητα

Στο δεύτερο μέρος της εργασίας ζητήθηκε να ακολουθηθεί μια πιο συστηματική προσέγγιση στο πρόβλημα μοντελοποίησης μιας άγνωστης συνάρτησης.

Το *dataset* το οποίο ζητήθηκε να χρησιμοποιηθεί είναι το Superconductivity dataset από το UCI Repository, το οποίο περιλαμβάνει 21263 δείγματα, καθένα από τα οποία περιγράφεται από 81 μεταβλητές/χαρακτηριστικά (αρχείο *superconduct.csv*).

Για ένα *dataset* με τέτοιο υψηλό βαθμό διαστασιμότητας, προκύπτει το πρόβλημα της λεγόμενης 'έκρηξης' του πλήθους των IF - THEN κανόνων (rule explosion). Για την κλασσική περίπτωση του grid partitioning του χώρου εισόδου, ο αριθμός των κανόνων αυξάνεται εκθετικά σε σχέση με το πλήθος των εισόδων, γεγονός που καθιστά πολύ δύσκολη την μοντελοποίηση μέσω ενός *TSK* μοντέλου ακόμα και για *datasets* μεσαίας κλίμακας. Στο παράδειγμά μας δηλαδή, έχοντας 81 μεταβλητές, αν διαμερίζαμε το χώρο εισόδου κάθε μεταβλητής με δύο ασαφή σύνολα, θα καταλήγαμε με  $2^{81}$  κανόνες. Έτσι θα πρέπει να χειριστούμε την υψηλή διαστασιμότητα του *dataset* μέσω της επιλογής χαρακτηριστικών και της χρήσης διαμέρισης διασκορπισμού.

Οι δύο αυτές μέθοδοι όμως, παρά την ελάττωση της πολυπλοκότητας που επιφέρουν, εισάγουν στο πρόβλημα δύο ελεύθερες παραμέτρους, συγκεκριμένα:

1. Τον αριθμό των χαρακτηριστικών προς επιλογή (feature selection): για μείωση της διαστασιμότητας.
2. Τον αριθμό των ομάδων που θα δημιουργηθούν (*clustering*): για αυτόματη εξαγωγή των κανόνων IF-THEN.

Η μοντελοποίηση του προβλήματος ακολουθεί τα εξής βήματα:

1. Διαχωρισμός σε σύνολα εκπαίδευσης - επικύρωσης - ελέγχου.
2. Επιλογή των βέλτιστων παραμέτρων μέσω της αναζήτησης πλέγματος (grid search) και αξιολόγησης με 5-πτυχή διασταυρωμένη επικύρωση (5-fold cross validation).
3. Εκπαίδευση ενός *TSK* μοντέλου με βάση τις βέλτιστες τιμές των παραμέτρων που υπολογίστηκαν.

## 2.1 Διαχωρισμός σε σύνολα εκπαίδευσης - επικύρωσης - ελέγχου

Όπως και στο πρώτο μέρος της εργασίας, ο διαμερισμός του *dataset* και η κανονικοποίηση των δεδομένων έγινε με χρήση της συνάρτησης *split\_scale*, και τα σύνολα εκπαίδευσης *Dtrn*, επικύρωσης *Dval* και ελέγχου *Dtst* κατέλαβαν το 60%, 20% και 20% αντίστοιχα των συνολικών δεδομένων.

## 2.2 Επιλογή των βέλτιστων παραμέτρων

Για την επιλογή των τιμών των ελεύθερων παραμέτρων του συστήματός μας χρησιμοποιούμε την αναζήτηση πλέγματος. Στην αναζήτηση πλέγματος, αφού λάβουμε ένα σύνολο τιμών για κάθε παράμετρο, δημιουργούμε ένα  $n$ -διάστατο πλέγμα όπου κάθε σημείο αντιστοιχεί σε μια  $n$ -άδα τιμών για τις εν λόγω παραμέτρους, και σε κάθε σημείο χρησιμοποιούμε μια μέθοδο αξιολόγησης για να ελέγξουμε την ορθότητα των συγκεκριμένων τιμών.

Στο πρόβλημά μας έχουμε ένα 2-διάστατο πλέγμα το οποίο αξιολογούμε με τη μέθοδο της διασταυρωμένης επικύρωσης. Σύμφωνα με τη μέθοδο αυτή, για επιλεγμένες τιμές των παραμέτρων χωρίζουμε το σύνολο εκπαίδευσης σε 2 υποσύνολα, από τα οποία το πρώτο αποτελείται από το 80% των δεδομένων εκπαίδευσης και χρησιμοποιείται για την εκπαίδευση ενός μοντέλου, και το δεύτερο αποτελείται από το 20% των δεδομένων εκπαίδευσης και χρησιμοποιείται για την αξιολόγηση του μοντέλου.

Στο τέλος κάθε επανάληψης λαμβάνουμε τον μέσο όρο του σφάλματος του μοντέλου, τον οποίο αποθηκεύουμε. Όταν η διαδικασία αυτή εκτελεστεί για κάθε σημείο του πλέγματος, λαμβάνουμε ως βέλτιστες τιμές των παραμέτρων τις τιμές που αντιστοιχούν στο μοντέλο που παρουσίασε το ελάχιστο μέσο σφάλμα.

Οι τιμές αυτές χρησιμοποιούνται στη συνέχεια για την εκπαίδευση του τελικού μας μοντέλου. Η διαδικασία αυτή υλοποιείται από τον κώδικα στο αρχείο *Regression\_2.m*.

Ορίζουμε τις παραμέτρους:

- **Αριθμός χαρακτηριστικών** που μοντελοποιεί το πλήθος των χαρακτηριστικών που θα χρησιμοποιηθούν στην εκπαίδευση των μοντέλων.

Ορίζεται μέσω της μεταβλητής (*num\_features*) = [5 8 10 12 15] και αποτελεί την πρώτη παράμετρο της αναζήτησης πλέγματος.

- **Ακτίνα των clusters** που καθορίζει την ακτίνα επιρροής των *clusters* και κατέ-  
πέκταση το πλήθος των κανόνων που θα προκύψουν.  
Ορίζεται μέσω της μεταβλητής (*cluster\_radius*) = [0.2 0.4 0.5 0.6 0.8] και αποτελεί  
την δεύτερη παράμετρο της αναζήτησης πλέγματος.


Για τη δημιουργία των *IF-THEN* κανόνων επιλέγεται ο αλγόριθμος Subtractive Clustering, ενώ για την επιλογή των χαρακτηριστικών ο αλγόριθμος *Relief* για k-nearest neighbors ( $k = \text{num\_nearest\_neighbors} = 10$ ).

Κάθε μοντέλο εκπαιδεύτηκε για 100 επαναλήψεις (*epochs*).

Ένα άλλο σημαντικό σημείο του κώδικα είναι πως για τη βελτίωση της υπολογιστικής αποδοτικότητας, η διαδικασία αναζήτησης πλέγματος εκτελέστηκε παράλληλα με χρήση της εντολής *parfor* του Parallel Computing Toolbox του *MATLAB*, επιτρέποντας την ταυτόχρονη αξιολόγηση πολλών συνδυασμών υπερπαραμέτρων.

Για κάθε σημείο του *grid*, ζεύγος (*num\_features*, *cluster\_radius*) αποθηκεύτηκε ο *MSE* και ο αριθμός κανόνων και με το πέρας της διαδικασίας οι τιμές όλων των μεταβλητών του *workspace* αποθηκεύτηκαν στο αρχείο *regression\_grid\_search.mat*.


Τα ζητούμενα διαγράμματα που απεικονίζουν το μέσο σφάλμα σε σχέση με τον αριθμό των κανόνων και σε σχέση με τον αριθμό των επιλεγθέντων χαρακτηριστικών φαίνονται στο Σχ. 18 και στο Σχ. 19.




Σχήμα 18: Mean Squared Error as a function of the Number of Fuzzy Rules.

Παρατηρούμε πως καθώς αυξάνεται ο αριθμός των κανόνων, το μέσο σφάλμα γενικά μειώνεται. Αυτό είναι λογικό αν αναλογιστούμε την αύξηση της πολυπλοκότητας και άρα της εκφραστικότητας του μοντέλου που συνεπάγεται η αύξηση των *fuzzy* κανόνων, η οποία ταυτόχρονα έχει όμως και το μειονέκτημα του αυξημένου υπολογιστικού κόστους.





Σχήμα 19: Mean Squared Error as a function of the number of selected features and the cluster influence range.



Σχήμα 20: Surface plot of MSE

Στο Σχ. 20 βλέπουμε και την τρισδιάστατη απεικόνιση της συνάρτησης μεταξύ του μέσου σφάλματος και του συνδυασμού των παραμέτρων. Από εδώ μπορούμε να παρατηρήσουμε καλύτερα πώς μεταβάλλεται η τιμή του  $MSE$  για διαφορετικές τιμές των ζευγών που μελετήθηκαν στην αναζήτηση πλέγματος. Το μέσο σφάλμα φαίνεται να μειώνεται προς την κατεύθυνση της αύξησης του αριθμού χαρακτηριστικών και ταυτόχρονα της ελάττωσης της ακτίνας του  $cluster$ , παίρνοντας την ελάχιστη τιμή του για μεγάλο αριθμό χαρακτηριστικών και ακτίνα κοντά στο 0.4. Η οπτικοποίηση αυτή έρχεται να επιβεβαιωθεί από τα αποτελέσματα που τυπώνονται στην κονσόλα με τη λήξη της αναζήτησης πλέγματος όπως φαίνεται στο Σχ. 21.

```

=== GRID SEARCH RESULTS ===
Lowest mean MSE: 218.076247
Best number of features: 15
Best cluster radius: 0.40
Corresponding number of rules: 9
=====


```

Σχήμα 21: Grid Search Results.


Έτσι, καταλήγουμε σε βέλτιστη συμπεριφορά για αριθμό χαρακτηριστικών 15 ακτίνα 0.4. Ο αριθμός κανόνων που προκύπτει είναι 9. Αποθηκεύονται οι βέλτιστες τιμές των παραμέτρων στις μεταβλητές *bestNumOfFeatures*, *bestClusterRadius* και *bestNumOfRules* για το επόμενο βήμα της εκπαίδευσης του τελικού μοντέλου.

### 2.3 Εκπαίδευση ενός TSK μοντέλου

Το τελικό μοντέλο που προέκυψε από την παραπάνω διαδικασία, εκπαιδεύτηκε επίσης για 100 *epochs*. Στο Σχ. 22 βλέπουμε τις προβλέψεις του μοντέλου σε σύγκριση με τις πραγματικές τιμές της εξόδου και στο Σχ. 23 το σφάλμα πρόβλεψης για τα δεδομένα ελέγχου.




Σχήμα 22: Predicted vs Actual values.




Σχήμα 23: Prediction Error.

Στο Σχ. 24 φαίνεται το διάγραμμα εκμάθησης όπου απεικονίζεται το σφάλμα εκπαίδευσης και επικύρωσης συναρτήσει του αριθμού επαναλήψεων.




Σχήμα 24: Learning Curve.

Παρατηρούμε πως στα πρώτα στάδια της εκπαίδευσης (περίπου ως την 30η επανάληψη) και οι 2 καμπύλες μειώνονται, γεγονός που δείχνει πως το μοντέλο μαθαίνει αποτελεσματικά. Ωστόσο από εκείνο το σημείο και μετά, το σφάλμα επικύρωσης αρχίζει να αυξάνεται, ενώ το σφάλμα εκπαίδευσης συνεχίζει να μειώνεται. Αυτή η απόκλιση των 2 καμπύλων αποτελεί ένδειξη υπερπροσαρμογής, δηλαδή ένδειξη ότι το μοντέλο αρχίζει να μαθαίνει λεπτομέρειες και θόρυβο του συνόλου εκπαίδευσης, χάνοντας τη δυνατότητα γενίκευσης σε νέα δεδομένα. Αυτό μπορεί να σημαίνει πως οι τιμές των παραμέτρων που επιλέχτηκαν από την αναζήτηση πλέγματος οδήγησαν σε ένα μοντέλο που τελικώς έχει υπερβολική εκφραστικότητα σε σχέση με το μέγεθος ή την πολυπλοκότητα των δεδομένων. Στη συνέχεια παρατίθενται μερικά ενδεικτικά ασαφή σύνολα στην αρχική (πριν την εκπαίδευση) και τελική τους μορφή (μετά την εκπαίδευση).




(α') Input 1 Before training




(β') Input 1 After training


Σχήμα 25: Membership functions of Inputs before and after ANFIS training. Each plot shows the degree of membership for the corresponding fuzzy sets.




( $\alpha'$ ) Input 2 Before training




( $\beta'$ ) Input 2 After training




( $\alpha'$ ) Input 3 Before training



( $\beta'$ ) Input 3 After training



( $\alpha'$ ) Input 4 Before training



( $\beta'$ ) Input 4 After training

Οι μετρικές απόδοσης του τελικού μοντέλου παρουσιάζονται στον πίνακα 3.

Πίνακας 3: Evaluation metrics of the final ANFIS model.

| Metric | RMSE   | NMSE    | NDEI    | $R^2$   |
|--------|--------|---------|---------|---------|
| Value  | 15.111 | 0.19383 | 0.44027 | 0.80612 |

Βλέπουμε πως ενώ η τιμή 15.111 του σφάλματος  $RMSE$  φαίνεται εκ πρώτης όψης ιδιαίτερα μεγάλη, η τιμή 0.80612 του συντελεστή προσδιορισμού  $R^2$  υποδηλώνει ισχυρή συσχέτιση μεταξύ πραγματικών και προβλεπόμενων τιμών.

Για να ερμηνεύσουμε την σημασία της τιμής του  $RMSE$  είναι καλό να ληφθεί υπόψη το είδος και το εύρος της μεταβλητής εξόδου του συνόλου δεδομένων το οποίο μελετάμε. Στο δεδομένο *dataset Superconductivity*, όπου η κρίσιμη θερμοκρασία (critical temperature) κυμαίνεται περίπου από 0 έως 185 K, η τιμή αυτή του  $RMSE$  αντιστοιχεί σε μέσο σχετικό σφάλμα περίπου 8%. Το γεγονός αυτό δείχνει ότι το μοντέλο περιγράφει ικανοποιητικά τη συσχέτιση μεταξύ των χαρακτηριστικών των υλικών και της κρίσιμης θερμοκρασίας, εξηγώντας περίπου το 80% της διακύμανσης των δεδομένων, γεγονός που δηλώνει επαρκή ακρίβεια.

## 2.4 Σχολιασμός

Το τελικό μας μοντέλο, παρότι παρουσιάζει μια σχετικά αυξημένη τιμή  $RMSE$ , επιτυγχάνει ικανοποιητική ακρίβεια με μόνο 9 κανόνες, ενώ η χρήση μεγαλύτερου πλήθους χαρακτηριστικών ή μικρότερης ακτίνας για το *clustering* θα οδηγούσε σε αύξηση της πολυπλοκότητας χωρίς σημαντική βελτίωση της απόδοσης. Η τιμή της ακτίνας υποδεικνύει έναν ικανοποιητικό βαθμό συγχώνευσης των δεδομένων, αποτρέποντας τη δημιουργία υπερβολικά εξειδικευμένων ή επικαλυπτόμενων κανόνων.

Συγκρίνοντας τα αποτελέσματα αυτού του μοντέλου, με τα αποτελέσματα των μοντέλων στο πρώτο μέρος της εργασίας γίνεται σαφές πως το μοντέλο αυτό δεν είναι τόσο ακριβές, που είναι λογικό αφού δεν χρησιμοποιούμε όλες τις μεταβλητές εισόδου για την εξαγωγή του αποτελέσματος αλλά μέρος μόνο αυτών. Αν είχαμε επιλέξει την μέθοδο του Grid Partitioning με δύο ή τρία ασαφή σύνολα ανά είσοδο, θα είχαμε εκθετική αύξηση των κανόνων IF-THEN, δηλαδή για τον ίδιο αριθμό χαρακτηριστικών,  $2^{15}$  ή  $3^{15}$  κανόνες αντίστοιχα, που την καθιστά υπολογιστικά ασύμφορη. Γίνεται σαφές έτσι το πλεονέκτημα που επιφέρει η χρήση του Subtractive Clustering, και η σημασία του για μεγάλα ή υψηλής διαστασιμότητας σύνολα δεδομένων, όπως το *Superconductivity*.