

Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης
Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών



Υπολογιστική Νοημοσύνη

Αναφορά Εργασίας 4. Classification

Τίτλος:

Επίλυση προβλήματος ταξινόμησης με χρήση μοντέλων TSK

Φοιτήτρια: Ζαχαριουδάκη Δανάη

A.M.: 9418

Ημερομηνία: Οκτώβριος 2025

Περιεχόμενα

1	Εφαρμογή 1: Απλό Dataset	2
1.1	Εκπαίδευση	2
1.2	TSK Model 1	3
1.3	TSK Model 2	6
1.4	TSK Model 3	8
1.5	TSK Model 4	10
1.6	Δείκτες απόδοσης	12
1.7	Σχολιασμός Αποτελεσμάτων	13
2	Εφαρμογή 2: Dataset με Υψηλή Διαστασιμότητα	14
2.1	Διαχωρισμός σε σύνολα εκπαίδευσης - επικύρωσης - ελέγχου	15
2.2	Επιλογή των βέλτιστων παραμέτρων	15
2.3	Εκπαίδευση ενός TSK μοντέλου	17
2.4	Σχολιασμός	21

1 Εφαρμογή 1: Απλό Dataset

Για το πρώτο μέρος της εργασίας, ο κώδικας που υπολοιεί την εκπαίδευση και αξιολόγηση των μοντέλων βρίσκεται στο αρχείο `TSK_Classification.m`. Κάνουμε χρήση του Haberman's survival dataset από το UCI repository. Περιλαμβάνονται 306 δείγματα (*instances*) με 3 χαρακτηριστικά (*attributes*) το καθένα. Στόχος μας είναι η διερεύνηση της διαδικασίας εκπαίδευσης και αξιολόγησης ασαφών νερωνικών μοντέλων σε προβλήματα ταξινόμησης.

1.1 Εκπαίδευση

Αρχικά ζητείται να γίνει διαχωρισμός του συνόλου δεδομένων σε τρία μη-επικαλυπτόμενα υποσύνολα:

1. Υποσύνολο εκπαίδευσης (Training set)
2. Υποσύνολο επικύρωσης (Validation set)
3. Υποσύνολο ελέγχου (Test set)

Αυτά αντιστοιχίζονται στις μεταβλητές του κώδικα *Dtrn*, *Dval*, και *Dtst* αντίστοιχα. Ο διαχωρισμός του *dataset* έγινε με χρήση της συνάρτησης `'stratified_sampling_split_scale'`, η οποία χωρίζει το σύνολο των δεδομένων ως εξής:

- 60% στο σύνολο εκπαίδευσης
- 20% στο σύνολο επικύρωσης
- 20% στο σύνολο ελέγχου

και κανονικοποιεί τα δεδομένα για τιμή της μεταβλητής *preproc* 1, αλλά ταυτόχρονα διατηρεί τις συχνότητες εμφάνισης των δεδομένων στα τρία υποσύνολα ίδια με την αντίστοιχη συχνότητα εμφάνισης στο αρχικό σύνολο δεδομένων. Αυτό οδηγεί σε πιο αξιόπιστη διαδικασία εκπαίδευσης και αξιολόγησης, μειώνοντας τις διαφορές στις επιδόσεις και τον πιθανότητα παραπλανητικής υψηλής ή χαμηλής ακρίβειας.

Εκπαιδεύτηκαν 4 *TSK* μοντέλα, τα οποία διαφέρουν ως προς το πλήθος των ασαφών IF-THEN κανόνων, με σκοπό να μελετηθεί η επίδραση της διαμέρισης του χώρου εισόδου σε συνάρτηση με την πολυπλοκότητα που αυτή επιφέρει, στην απόδοση του ταξινομητή.

Η διαμέριση του χώρου εισόδου έγινε με τη μέθοδο του Subtractive Clustering. Τα μοντέλα διαφέρουν ως προς την παράμετρο που καθορίζει τον αριθμό των κανόνων, δηλαδή ως προς το μέγεθος / ακτίνα των *clusters*. Επειδή θέλουμε να συγκρίνουμε τα αποτελέσματα των ταξινομητών μας ως προς την παράμετρο αυτή, επιλέγουμε δύο ακραίες τιμές:

`cluster_radius = [0.1 0.9]` για να είναι μεγάλες οι διαφοροποιήσεις.

Για τα πρώτα δύο μοντέλα, η διαμέριση του χώρου εισόδου εκτελέστηκε για όλα τα δεδομένα του συνόλου εκπαίδευσης, τα μοντέλα είναι δηλαδή Class-Independent, ενώ για τα μοντέλα 3

και 4, εξετάστηκε ο διαμερισμός του χώρου εισόδου εφαρμόζοντας *clustering* στα δεδομένα του συνόλου εκπαίδευσης που ανήκουν στην εκάστοτε κλάση ξεχωριστά, πρόκειται δηλαδή για μοντέλα Class-Dependent.


Όλα τα μοντέλα εκπαιδεύτηκαν με την υβριδική μέθοδο, με τη βελτιστοποίηση των συναρτήσεων συμμετοχής να γίνεται μέσω της μεθόδου της οπισθοδιάσωσης (*backpropagation*), ενώ η βελτιστοποίηση των παραμέτρων της συνάρτησης εξόδου γίνεται μέσω της μεθόδου των ελαχίστων τετραγώνων (Least Squares).

Η εκπαίδευση έγινε κάθε φορά για 100 *epochs*. Για την διαχείριση των τιμών εξόδου που αντιστοιχούν κάθε φορά σε μια κλάση (είναι δηλαδή ακέραιοι αριθμοί), έγινε χειροκίνητη αλλαγή του τύπου της συνάρτησης εξόδου σε *Singleton* μέσω της μεταβλητής `outputMembershipFunctionType = 'constant'`, η οποία δόθηκε έπειτα ως όρισμα στην συνάρτηση `addMF`. Επίσης η μεταβλητή στόχος που προκύπτει από τις προβλέψεις του μοντέλου y_{pred} στρογγυλοποιήθηκε στον πλησιέστερο ακέραιο μέσω της συνάρτησης `round()` και σε περίπτωση που παρέκλινε από το σύνολο 1, 2 επαναπροσδιορίστηκε εντός αυτού θέτοντας την τιμή της ίση με $\min(\max(1, y_{pred}), 2)$.


1.2 TSK Model 1

Τα διαγράμματα συναρτήσεων συμμετοχής όπου απεικονίζονται οι τελικές μορφές των ασάφων συνόλων που προέκυψαν μέσω της διαδικασίας εκπαίδευσης φαίνονται στο Σχ. 2.


Το διάγραμμα μάθησης (*Learning curve*) όπου απεικονίζεται το σφάλμα εκπαίδευσης και το σφάλμα επικύρωσης του μοντέλου συναρτήσει του αριθμού των επαναλήψεων φαίνεται στο Σχ. 3, ενώ ο Error Matrix στο Σχ. 1.




Σχήμα 1: Error Matrix of TSK model 1.



(α') Input 1: Age




(β') Input 2: Year of Operation



(γ') Input 3: Number of Positive Axillary Nodes


Σχῆμα 2: Membership functions.




Σχήμα 3: Learning Curve of TSK model 1.

1.3 TSK Model 2


Αντίστοιχα παρατίθενται για το δεύτερο μοντέλο τα διαγράμματα συναρτήσεων συμμετοχής στο Σχ. 5, το διάγραμμα μάθησης (*Learning curve*) στο Σχ. 6 και ο Error Matrix στο Σχ. 4.




Σχήμα 4: Error Matrix of TSK model 2.



(α') Input 1: Age




(β') Input 2: Year of Operation



(γ') Input 3: Number of Positive Axillary Nodes


Σχήμα 5: Membership functions.




Σχήμα 6: Learning Curve of TSK model 2.

1.4 TSK Model 3


Αντίστοιχα για το τρίτο μοντέλο, τα διαγράμματα συναρτήσεων συμμετοχής στο Σχ. 8, το διάγραμμα μάθησης (*Learning curve*) στο Σχ. 9 και ο Error Matrix στο Σχ. 7.




Σχήμα 7: Error Matrix of TSK model 3.



(α') Input 1: Age




(β') Input 2: Year of Operation



(γ') Input 3: Number of Positive Axillary Nodes


Σχρήμα 8: Membership functions.




Σχήμα 9: Learning Curve of TSK model 3.

1.5 TSK Model 4


Και τέλος για το τέταρτο και τελευταίο μοντέλο, τα διαγράμματα συναρτήσεων συμμετοχής στο Σχ. 11, το διάγραμμα μάθησης (*Learning curve*) στο Σχ. 12 και ο Error Matrix στο Σχ. 10.




Σχήμα 10: Error Matrix of TSK model 4.



(α') Input 1: Age




(β') Input 2: Year of Operation



(γ') Input 3: Number of Positive Axillary Nodes

$\Sigma\chi\eta\mu\alpha$ 11: Membership functions.



Σχήμα 12: Learning Curve of TSK model 4.

1.6 Δείκτες απόδοσης

Για κάθε μοντέλο αποθηκεύτηκε σε έναν πίνακα num_model_rules ο αριθμός των κανόνων που προέκυψαν με βάση την ακτίνα που τους αποδόθηκε κατά την δημιουργία τους. Τα παραπάνω χαρακτηριστικά για κάθε μοντέλο βλέπουμε στον πίνακα 1. Τα αποτελέσματα των δεικτών απόδοσης όπως προκύπτουν από τον πίνακα σφαλμάτων ταξινόμησης παρουσιάζονται για κάθε μοντέλο στον πίνακα 2.

Table 1: Model characteristics

Model	Class Dependency	Cluster Radius	Number of Rules
TSK Model 1	Independent	0.1	121
TSK Model 2	Independent	0.9	2
TSK Model 3	Dependent	0.1	127
TSK Model 4	Dependent	0.9	2

Table 2: Performance metrics for the TSK classification models

Model	OA	PA (Class 1)	PA (Class 2)	UA (Class 1)	UA (Class 2)	$\hat{K}$
1	0.68852	0.79167	0.30769	0.80851	0.28571	0.09665
2	0.83607	0.95833	0.38462	0.85185	0.71429	0.41233
3	0.70492	0.79167	0.38462	0.82609	0.33333	0.16692
4	0.80328	0.95833	0.23077	0.82143	0.60000	0.24380

1.7 Σχολιασμός Αποτελεσμάτων

Βλέπουμε πως την καλύτερη συνολική ακρίβεια, μεγαλύτερο ποσοστό δηλαδή ορθώς ταξινομημένων δειγμάτων ως προς το συνολικό πλήθος των δειγμάτων, έχουμε στην περίπτωση των μοντέλων 2 και 4, των μοντέλων δηλαδή με το μικρότερο αριθμό κανόνων.

Το ίδιο ισχύει και για τον δείκτη K (Cohen's Kappa), ο οποίος δείχνει πόσο καλά προβλέπει το μοντέλο αν αφαιρέσουμε την τυχαία συμφωνία. Πολύ μικρές τιμές του K όπως στην περίπτωση των μοντέλων 1 και 3 ερμηνεύονται ως σχεδόν τυχαία πρόβλεψη, ενώ στην περίπτωση των μοντέλων 2 και 4 μέτρια πρόβλεψη. Υψηλή ακρίβεια σε συνδυασμό με χαμηλή τιμή του δείκτη K μας δείχνει πως το μοντέλο προβλέπει σωστά, αλλά κυρίως την κυρίαρχη κλάση.

Αναφορικά με τους δείκτες που αποτυπώνουν την απόδοση του ταξινομητή για κάθε κλάση ξεχωριστά, την ακρίβεια παραγωγού (Producer's accuracy) και την ακρίβεια χρήστη (User's accuracy), παρατηρούμε ότι γενικά το μοντέλο 2 πάντα έχει την καλύτερη τιμή, ενώ για όλα τα μοντέλα, οι δείκτες που εξετάζουν την κλάση 1 είναι πολύ υψηλότεροι από αυτούς της κλάσης 2. Αυτό μας δείχνει πως τα μοντέλα προβλέπουν με πολύ μεγαλύτερη ακρίβεια τα δείγματα που ανήκουν στην κλάση 1. Αυτό μάλλον οφείλεται σε ανισορροπία στα δεδομένα η οποία επηρεάζει τις προβλέψεις των ταξινομητών. Η κλάση 1 μπορεί να περιέχει δηλαδή πολύ περισσότερα δείγματα από την κλάση 2 με αποτέλεσμα οι ταξινομητές να μαθαίνουν να την εντοπίζουν πολύ καλύτερα. Πάλι φαίνεται ότι ο μεγάλος αριθμός κανόνων δεν επιδρά θετικά στο μοντέλο, ίσως επειδή γίνεται υπερβολικά περίπλοκο και τείνει να υπερπροσαρμόζεται στα δεδομένα εκπαίδευσης, χωρίς να γενικεύει καλά στο σύνολο ελέγχου.

Όταν η ακτίνα είναι μικρή (0.1), οι περιοχές επιρροής των κανόνων επικαλύπτονται έντονα. Αυτό οδηγεί σε ταυτόχρονη ενεργοποίηση πολλών κανόνων για το ίδιο δείγμα. Αντίθετα, με μεγαλύτερη ακτίνα (0.9), οι περιοχές είναι πιο διακριτές, άρα κάθε δείγμα ενεργοποιεί λιγότερους κανόνες με πιο ξεκάθαρη συμβολή στην έξοδο. Αυτό βελτιώνει τη γενίκευση και μειώνει το θόρυβο. Τα παραπάνω συμπεραίνουμε παρατηρώντας και τα διαγράμματα των συναρτήσεων συμμετοχής.

Για την επίδραση της εξάρτησης από την τάξη δεν μπορεί να εξαχθεί κάποιο συμπέρασμα, καθώς τα αποτελέσματα των ταξινομητών φαίνεται να εξαρτώνται πιο έντονα από τον αριθμό των κανόνων δεδομένης και την ανισορροπίας των δεδομένων του *dataset*.

Για την βελτίωση του μοντέλου μια ικανοποιητική λύση θα ήταν να γίνει ρύθμιση του `cluster_radius` έτσι ώστε να επιτυγχάνεται μια ισορροπία μεταξύ πολυπλοκότητας και ακρίβειας — π.χ. τιμές μεταξύ 0.3–0.6 θα μπορούσαν να προσφέρουν καλύτερη ισορροπία. Επίσης η επανασχεδίαση των συναρτήσεων συμμετοχής ώστε να μειώνεται η επικάλυψη χωρίς μεγάλη απώλεια πληροφορίας.

2 Εφαρμογή 2: Dataset με Υψηλή Διαστασιμότητα

Στο δεύτερο μέρος της εργασίας ζητήθηκε να ακολουθηθεί μια πιο συστηματική προσέγγιση στο πρόβλημα της χρήσης ασαφών νευρωνικών μοντέλων σε προβλήματα ταξινόμησης.

Το *dataset* το οποίο ζητήθηκε να χρησιμοποιηθεί είναι το Epileptic Seizure Recognition dataset από το UCI Repository, το οποίο περιλαμβάνει 11500 δείγματα, καθένα από τα οποία περιγράφεται από 179 μεταβλητές/χαρακτηριστικά (αρχείο `epileptic_seizure_data.csv`).

Για ένα *dataset* με τέτοιο υψηλό βαθμό διαστασιμότητας, προκύπτει το πρόβλημα της λεγόμενης 'έκρηξης' του πλήθους των IF - THEN κανόνων (rule explosion). Για την κλασσική περίπτωση του grid partitioning του χώρου εισόδου, ο αριθμός των κανόνων αυξάνεται εκθετικά σε σχέση με το πλήθος των εισόδων, γεγονός που καθιστά πολύ δύσκολη την μοντελοποίηση μέσω ενός *TSK* μοντέλου ακόμα και για *datasets* μεσαίας κλίμακας. Στο παράδειγμά μας δηλαδή, έχοντας 179 μεταβλητές, αν διαμερίζαμε το χώρο εισόδου κάθε μεταβλητής με δύο ασαφή σύνολα, θα καταλήγαμε με το ασύληπτο νούμερο των 2^{179} κανόνων. Έτσι θα πρέπει να διαχειριστούμε την υψηλή διαστασιμότητα του *dataset* μέσω της επιλογής χαρακτηριστικών και της χρήσης διαμέρισης διασκορπισμού.

Οι δύο αυτές μέθοδοι όμως, παρά την ελάττωση της πολυπλοκότητας που επιφέρουν, εισάγουν στο πρόβλημα δύο ελεύθερες παραμέτρους:

1. Τον αριθμό των χαρακτηριστικών προς επιλογή (feature selection): για μείωση της διαστασιμότητας.
2. Τον αριθμό των ομάδων που θα δημιουργηθούν (*clustering*): για αυτόματη εξαγωγή των κανόνων IF-THEN.

Η μοντελοποίηση του προβλήματος ακολουθεί τα εξής βήματα:

1. Διαχωρισμός σε σύνολα εκπαίδευσης - επικύρωσης - ελέγχου.
2. Επιλογή των βέλτιστων παραμέτρων μέσω της αναζήτησης πλέγματος (grid search) και αξιολόγησης με 5-πτυχή διασταυρωμένη επικύρωση (5-fold cross validation).
3. Εκπαίδευση ενός *TSK* μοντέλου με βάση τις βέλτιστες τιμές των παραμέτρων που υπολογίστηκαν και έλεγχος της απόδοσής του στο σύνολο ελέγχου.

2.1 Διαχωρισμός σε σύνολα εκπαίδευσης - επικύρωσης - ελέγχου

Όπως και στο πρώτο μέρος της εργασίας, ο διαμερισμός του *dataset* και η κανονικοποίηση των δεδομένων έγινε με χρήση της συνάρτησης *stratified_sampling_split_scale*, και τα σύνολα εκπαίδευσης *Dtrn*, επικύρωσης *Dval* και ελέγχου *Dtst* κατέλαβαν το 60%, 20% και 20% αντίστοιχα των συνολικών δεδομένων, διατηρώντας την κατανομή των κλάσεων.

2.2 Επιλογή των βέλτιστων παραμέτρων

Για την επιλογή των τιμών των ελεύθερων παραμέτρων του συστήματός μας χρησιμοποιούμε την αναζήτηση πλέγματος. Στην αναζήτηση πλέγματος, αφού λάβουμε ένα σύνολο τιμών για κάθε παράμετρο, δημιουργούμε ένα n -διάστατο πλέγμα όπου κάθε σημείο αντιστοιχεί σε μια n -άδα τιμών για τις εν λόγω παραμέτρους, και σε κάθε σημείο χρησιμοποιούμε μια μέθοδο αξιολόγησης για να ελέγξουμε την ορθότητα των συγκεκριμένων τιμών.

Στο πρόβλημά μας έχουμε ένα 2-διάστατο πλέγμα το οποίο αξιολογούμε με τη μέθοδο της διασταυρωμένης επικύρωσης. Σύμφωνα με τη μέθοδο αυτή, για επιλεγμένες τιμές των παραμέτρων χωρίζουμε το σύνολο εκπαίδευσης σε 2 υποσύνολα, από τα οποία το πρώτο αποτελείται από το 80% των δεδομένων εκπαίδευσης και χρησιμοποιείται για την εκπαίδευση ενός μοντέλου, και το δεύτερο αποτελείται από το 20% των δεδομένων εκπαίδευσης και χρησιμοποιείται για την αξιολόγηση του μοντέλου. Η μέθοδος υλοποιείται στον κώδικά μας μέσω της συνάρτησης *cvpartition()*, όπου δίνονται ως ορίσματα και ο αριθμός των στρώσεων (*num_folds* = 5) αλλά και η επιλογή ('Stratify', true) ώστε να διατηρηθεί και κατά τη διαδικασία αυτή η κατανομή των κλάσεων στα δύο υποσύνολα.

Στο τέλος κάθε επανάληψης λαμβάνουμε τον μέσο όρο του σφάλματος του μοντέλου, τον οποίο αποθηκεύουμε. Όταν η διαδικασία αυτή εκτελεστεί για κάθε σημείο του πλέγματος, λαμβάνουμε ως βέλτιστες τιμές των παραμέτρων τις τιμές που αντιστοιχούν στο μοντέλο που παρουσίασε το ελάχιστο μέσο σφάλμα.

Οι τιμές αυτές χρησιμοποιούνται στη συνέχεια για την εκπαίδευση του τελικού μας μοντέλου. Η διαδικασία αυτή υλοποιείται από τον κώδικα στο αρχείο *Classification_2.m*. Ορίστηκαν οι παράμετροι:

- Αριθμός χαρακτηριστικών (*num_features*) = [5 8 10 12].
- Ακτίνα των clusters (*cluster_radius*) = [0.2 0.4 0.5 0.6].

Ως μέθοδος διαμέρισης διασκορπισμού επιλέγεται ο αλγόριθμος Subtractive Clustering, ενώ για την επιλογή των χαρακτηριστικών ο αλγόριθμος *Relief*, με identifier ('method','classification'), καθώς η *relieff()* λειτουργεί με default το regression. Επίσης προσθέτουμε στα ορίσματά της *k*-nearest neighbors, ($k = \text{num_nearest_neighbors} = 10$).


Επιπλέον, η διαδικασία του subtractive clustering εφαρμόστηκε ξεχωριστά για κάθε κλάση, και η συνολική βάση κανόνων προέκυψε ως η ένωση των επιμέρους κανόνων που προέκυψαν από τις class-specific ομαδοποιήσεις. Κάθε μοντέλο εκπαιδεύτηκε για 100 επαναλήψεις

(*epochs*).

Όπως και στην εργασία παλινδρόμησης, για τη βελτίωση της υπολογιστικής αποδοτικότητας, η διαδικασία αναζήτησης πλέγματος εκτελέστηκε παράλληλα με χρήση της εντολής *parfor* του Parallel Computing Toolbox του *MATLAB*, επιτρέποντας την ταυτόχρονη αξιολόγηση πολλών συνδυασμών υπερπαραμέτρων και επιταχύνοντας την πολύ χρονοβόρα διαδικασία.


Για κάθε σημείο του *grid*, ζεύγος (*num_features*, *cluster_radius*) αποθηκεύτηκε ο *MSE* και ο αριθμός κανόνων και με το πέρας της διαδικασίας οι τιμές όλων των μεταβλητών του *workspace* αποθηκεύτηκαν στο αρχείο *classification_grid_search.mat*.

Τα ζητούμενα διαγράμματα που απεικονίζουν το μέσο σφάλμα σε σχέση με τον αριθμό των κανόνων και σε σχέση με τον αριθμό των επιλεχθέντων χαρακτηριστικών φαίνονται στο Σχ. 13 και στο Σχ. 14.



Σχήμα 13: Mean Squared Error as a function of the Number of Fuzzy Rules.

Παρατηρούμε από το surface plot πώς μεταβάλλεται το μέσο σφάλμα συναρτήσει του συνδυασμού του αριθμού χαρακτηριστικών και της ακτίνας συστάδων. Βλέπουμε πως ενώ το σφάλμα τείνει να μειωθεί για μεγαλύτερο αριθμό χαρακτηριστικών, εκτοξεύεται απότομα αν ταυτόχρονα με την αύξηση του αριθμού χαρακτηριστικών υπάρχει μεγάλη μείωση της ακτίνας (μικρότερη του 0.4). Έτσι ενώ φαίνεται να παίρνουμε την μικρότερη τιμή σφάλματος για ακτίνα στην περιοχή του 0.4-0.5 και αριθμό χαρακτηριστικών 12, αν μειώσουμε και άλλο την ακτίνα το μοντέλο γίνεται πολύ περίπλοκο και οδηγείται σε υπερπροσαρμογή. Η βέλτιστη περιοχή της επιφάνειας που παρατηρήσαμε επιβεβαιώνεται και από τα αποτελέσματα που τυπώνονται στην κονσόλα με τη λήξη της αναζήτησης πλέγματος και φαίνονται στο Σχ. 15.



Σχήμα 14: Surface plot of MSE

Έτσι, επιλέγουμε για τις παραμέτρους μας:

- Αριθμό Χαρακτηριστικών 12
- Ακτίνα 0.4

Προκύπτει: Αριθμός Κανόνων 13.

Αποθηκεύονται οι βέλτιστες τιμές των παραμέτρων στις μεταβλητές *bestNumOfFeatures*, *bestClusterRadius* και *bestNumOfRules* για το επόμενο βήμα της εκπαίδευσης του τελικού μοντέλου.

```


=== GRID SEARCH RESULTS ===
Lowest mean MSE: 1.127536
Best number of features: 12
Best cluster radius: 0.40
Corresponding number of rules: 13
=====

```

Σχήμα 15: Grid Search Results.


2.3 Εκπαίδευση ενός TSK μοντέλου

Το τελικό μοντέλο, με παραμέτρους που προέκυψαν από την παραπάνω διαδικασία, εκπαιδεύτηκε επίσης για 100 *epochs*. Στο Σχ. 16 βλέπουμε τις προβλέψεις του μοντέλου σε σύγκριση με τις πραγματικές τιμές της εξόδου.




Σχήμα 16: Predicted vs Actual values.

Στο Σχ. 17 φαίνεται το διάγραμμα εκμάθησης όπου απεικονίζεται το σφάλμα εκπαίδευσης και επικύρωσης συναρτήσει του αριθμού επαναλήψεων.




Σχήμα 17: Learning Curve.

Στη συνέχεια παρατίθενται μερικά ενδεικτικά ασαφή σύνολα στην αρχική (πριν την εκπαίδευση) και τελική τους μορφή (μετά την εκπαίδευση).




(α) Input 1 Before training




(β') Input 1 After training


Σχρμα 18: Membership functions of Inputs before and after ANFIS training. Each plot shows the degree of membership for the corresponding fuzzy sets.




(α) Input 2 Before training




(β') Input 2 After training




(α) Input 3 Before training



(β') Input 3 After training



(α') Input 4 Before training



(β') Input 4 After training

Ο πίνακας σφαλμάτων ταξινόμησης παρουσιάζεται στο Σχ. 22 και οι μετρικές απόδοσης που εξάγονται από αυτόν στον πίνακα 3.

Confusion Matrix of Optimal ANFIS						
True Class	1	2	3	4	5	
	341	67	44	8		
	25	24	295	116		
	2	16	296	144	2	
	1	23	194	221	21	
		3	165	267	25	
		1	2	3	4	5
		Predicted Class				

Σχήμα 22: Error Matrix.

Table 3: Classification metrics for the Optimal ANFIS model

Metric	Value
Overall Accuracy	0.39435
Producer Accuracy (Class 1)	0.7413
Producer Accuracy (Class 2)	0.0522
Producer Accuracy (Class 3)	0.6435
Producer Accuracy (Class 4)	0.4804
Producer Accuracy (Class 5)	0.0543
User Accuracy (Class 1)	0.9241
User Accuracy (Class 2)	0.1805
User Accuracy (Class 3)	0.2978
User Accuracy (Class 4)	0.2923
User Accuracy (Class 5)	0.5208
Kappa Coefficient (κ)	0.24293

2.4 Σχολιασμός

Το τελικό μας μοντέλο όπως αναμένεται έχει χαμηλή συνολική ακρίβεια (0.39), σημαντικά μειωμένη σε σχέση με τα *TSK* μοντέλα που μελετούσαμε στο απλό *dataset* του πρώτου μέρους της εργασίας, και είναι αναμενόμενο αφού δεν χρησιμοποιούμε όλες τις μεταβλητές εισόδου για την εξαγωγή του αποτελέσματος.

Ο συντελεστής *kappa* επίσης είναι χαμηλός (0.24). Συνδυαστικά από τα παραπάνω μπορούμε να αποφανθούμε πως το μοντέλο επιτυγχάνει σωστή ταξινόμηση σε 4/10 δείγματα με απόδοση λίγο καλύτερη από την τυχαία πρόβλεψη. Με άλλα λόγια, ο ταξινομητής έχει μάθει να αναγνωρίζει κάποιες σχέσεις στη δομή των δεδομένων, αλλά δεν έχει καταφέρει να γενικεύσει πλήρως. Αυτό γίνεται αντιληπτό και από το Σχ. 16 όπου βλέπουμε τις προβλέψεις του μοντέλου σε σχέση με τις πραγματικές τιμές να προσπαθούν να προσεγγίσουν τη διαγώνιο όπου οι 2 ταυτίζονται, αλλά χωρίς μεγάλη επιτυχία.

Το ασαφές σύστημα συμπερασμού με χρήση 13 κανόνων βελτιστοποιεί την απόδοσή του διατηρώντας ταυτόχρονα χαμηλή την πολυπλοκότητά του.

Σε περίπτωση που θέλαμε για τον ίδιο αριθμό χαρακτηριστικών να κάνουμε χρήση της μεθόδου του grid partitioning με δύο ή τρία ασαφή σύνολα ανά είσοδο, θα είχαμε εκθετική αύξηση των κανόνων IF-THEN, δηλαδή για τον ίδιο αριθμό χαρακτηριστικών, 2^{12} ή 3^{12} κανόνες αντίστοιχα.

Από τον πίνακα των μετρικών ταξινόμησης βλέπουμε εκτός από την χαμηλή συνολική ακρίβεια

και μεγάλη απόκλιση των μετρικών Producer Accuracy, User Accuracy μεταξύ των κλάσεων. Για παράδειγμα βλέπουμε πως το μοντέλο αναγνωρίζει σωστά τα περισσότερα δείγματα της κλάσης 1 και όταν προβλέπει “Class 1”, σχεδόν πάντα έχει δίκιο. ($PA = 0.74$, $UA = 0.92$) Αυτή είναι η πιο αξιόπιστη κλάση. Αντιθέτως για την κλάση 2, ($PA = 0.05$, $UA = 0.18$) δυσκολεύεται να ξεχωρίσει αυτήν την κλάση και την μπερδεύει με άλλες. Εδώ εντοπίζουμε το πρόβλημα διαχωρισιμότητας το οποίο μπορεί να οφείλεται σε χαμηλό signal-to-noise ratio και επικαλυπτόμενα χαρακτηριστικά. Η κλάση 3 $PA = 0.64$, $UA = 0.30$ αναγνωρίζεται με σχετικά καλή απόδοση αλλά πολλές από τις προβλέψεις “Class 3” είναι λανθασμένες. Για την κλάση 4 ($PA = 0.48$, $UA = 0.29$) σχεδόν τα μισά δείγματα αναγνωρίζονται σωστά αλλά η κλάση φαίνεται να συγχέεται με άλλες όπως φαίνεται και στο Error Matrix. Τέλος, η κλάση 5 ($PA = 0.05$, $UA = 0.52$) σπάνια αναγνωρίζεται σωστά, αλλά όταν το μοντέλο προβλέπει “Class 5”, περίπου τις μισές φορές η πρόβλεψη είναι σωστή. Συνολικά μπορούμε να καταλήξουμε ότι η χαμηλή συνολική ακρίβεια δείχνει ότι το μοντέλο, παρά τη βελτιστοποίηση μέσω του *grid search*, δεν έχει αρκετή εκφραστικότητα για ικανοποιητική ταξινόμηση στα δεδομένα του `epileptic_seizure_data`.